

检索技术说明：关键词与语义

DES-011 | 版本 1.0 | 搜索开发组 | 2026-09-15

1. 两种检索解决的问题

关键词检索适合已知文件名、任务编号、错误代码或原文术语的场景。用户输入 DOC-238 时，准确找到含有该标识的资料，比返回主题相近的资料更有用。中文正文需要适当分词；对编号和专有名称应避免把连续标识拆得无法匹配。

语义检索先把查询与文档片段表示为向量，再按相似性选择候选内容。例如用户问“同样的网络请求发两遍，会不会生成两份记录”，可能需要找到标题中含有“幂等”的接口约定。相似性表示关联程度，不代表片段中的结论一定正确或最新。

2. 一份文档进入索引的过程

保存原文件后，提取文本，按章节或自然段切分片段，为片段生成向量，并记录 documentId、内容版本、片段顺序和分类。保留原文用于显示相关片段，不能只保存一个不带来源的向量。

本项目初始方案按标题与段落切分，过长段落再拆分，相邻片段保留少量重叠。片段过短可能缺少语境，过长则容易混入多个主题，具体长度需要通过测试资料验证。这里不把某个固定长度视为对所有文档都有效。

3. 过滤和结果组织

检索应使用一致的模型与索引版本。更换向量模型时，应明确重建策略，避免把不兼容的向量混合计算。分类与归档状态都需要参与结果过滤，不能在默认搜索中返回已经归档的内容。

同一文件可能有多个片段命中。结果可以按文档聚合，展示最相关的一到两个片段，并允许定位更多内容。相似标题不能作为合并依据，聚合必须使用文档标识。

4. 不同资料类型的处理

资料特征	主要检索方式	核对重点
编号、接口路径、错误代码	关键词或精确匹配	字符是否被分词、规范化或转义破坏
不知道术语的自然语言问题	向量检索	是否返回真正解释该问题的原文片段
名称相近的规范和执行记录	名称搜索结合类型、归属信息	不能把一次历史事件当作长期规则
已归档的旧项目资料	显式进入归档范围检索	默认范围不泄漏归档记录

5. 如何评估

准备问题、可接受的目标文档以及相关片段依据。评估时区分没有召回目标、目标排序靠后、来源展示错误和片段缺少上下文。不能因为结果看起来主题相近，就认为已经解决了用户问题。

不要只用从文档中原样复制的句子测试语义能力。应包含改写、口语表达和用途描述，同时保留编号类精确查询，用来观察语义方法是否损害了本来容易找到的结果。

6. 与问答的边界

本阶段只要求定位资料，不要求系统生成综合回答。若未来增加问答，应展示实际引用来源，并处理资料之间的版本差异。检索分数不是置信概率，不能直接展示为“答案正确率”。

本说明是实现方向与评估方法，不包含真实性能测试数据。具体模型、资源占用和检索质量应以部署环境中的实际测量为准。